PORTFOLIO

UPDATED 2026.10

AI AGENT ENGINEER

만들고, 측정하고, 안정화합니다.

LLM Agent · RAG · Tool Calling을 구현하고,
평가와 테스트로 실제 환경에서 검증합니다.

정은희

EUNHEE JEONG

Python · LangGraph · Spring AI · Evaluation

github.com/Eunhee-JJ

ABOUT

LLM Agent를 만들고, 평가로 검증합니다

AI Agent 엔지니어 정은희입니다.

SK AI 전문가 양성과정 SKALA 참여 중 · Python / Java

Agent를 서비스에 쓰려면 잘 동작하는지 측정할 수 있고, 실패할 때도 안전하게 멈출 수 있어야 한다고 생각합니다. 그래서 멀티 에이전트에서는 근거가 없으면 판단을 유보하는 보고서 파이프라인을 설계했고, 상담 Agent에서는 출처 · 권한 · 행동을 채점하는 Golden Set으로 응답을 검증했습니다. YouTube Tool에서는 Mock 테스트로는 드러나지 않던 실제 API 실패를 재현 테스트로 찾아 안정화했습니다.

01

Agent 개발

Tool Calling · RAG · Memory · 멀티 에이전트 워크플로우 구현

02

평가 · 실험

Golden Set 평가 파이프라인 구축, 실험 설계 및 지표 기반 모델 선정

03

백엔드 · 운영

REST API · 동시성 제어 · Docker · CI/CD · MLOps

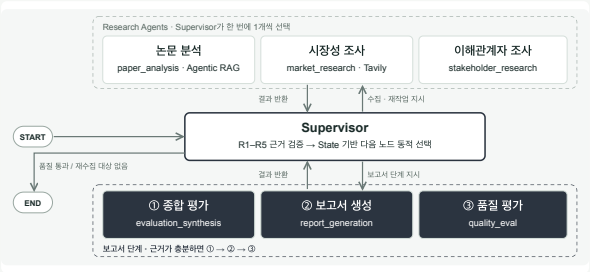
SKILLS

LANGUAGES	Python, Java, C#
AI / ML	PyTorch, LoRA SFT (Qwen2.5-1.5B), V-JEPA
AGENT / RAG	LangChain, LangGraph, Spring AI, Tool Calling, pgvector
BACKEND	Spring Boot, FastAPI, REST API
FRONTEND / XR	Vue 3, Unity
DATA / INFRA	PostgreSQL, Docker, Cloud Run, GitHub Actions, MLflow

GitHub · github.com/Eunhee-JJ

PROJECTS

주요 프로젝트



01

KV Cache 기술 평가 멀티 에이전트

LangGraph Supervisor · 근거 기반 보고서



02

마케팅 리서치 Agent

실제 API 실패 안정화 · 분석 초안 7초



03

티켓 환불 상담 Agent

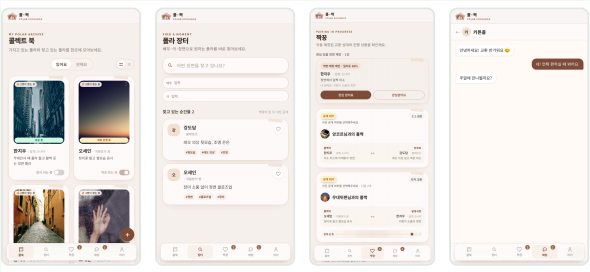
Spring AI RAG + Tool Calling · 평가 6/6

실험	Fine-tuned 승/패/무	Token F1	Total
은희 (Trial 1)	20 / 0 / 0	0.3100	0.3852
은희2 (Trial 2·최종)	**20 / 0 / 0**	**0.3569**	**0.3913**
은희3 (Trial 3)	19 / 0 / 1	0.3137	0.3735

04

sLLM 도메인 파인튜닝 (LoRA SFT)

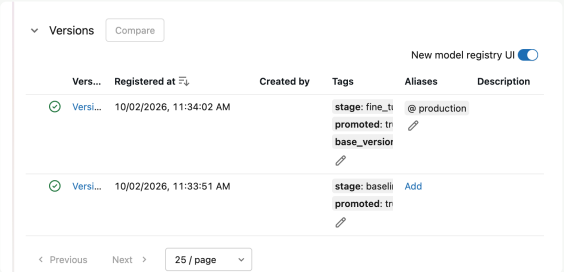
LoRA SFT · Base 대비 20문항 전승



05

폴짝 | 폴라로이드 교환 플랫폼

1인 풀스택 · 시맨틱 검색 · AI Fallback



06

BDI AIOps

MLOps · 검증 게이트 기반 모델 승격

LANGGRAPH · SUPERVISOR · MULTI-AGENT

KV Cache 기술 평가 멀티 에이전트

LangGraph Supervisor 패턴 멀티 에이전트의 종합 평가 · 보고서 생성 · 품질 평가 노드 개발

6인 팀 · 담당 E: 보고서 단계 3개 노드 + Supervisor 라우팅 · LangGraph · Python · Jinja2

Supervisor 기반 동적 라우팅

고정 순서 파이프라인을 Supervisor가 State(audit · node_status · retry_count)로 다음 Agent를 고르는 구조로 초기 구현, 라우팅 계약 보강 · 실패 Worker 1회 재시도

근거 기반 생성 (Grounded Generation)

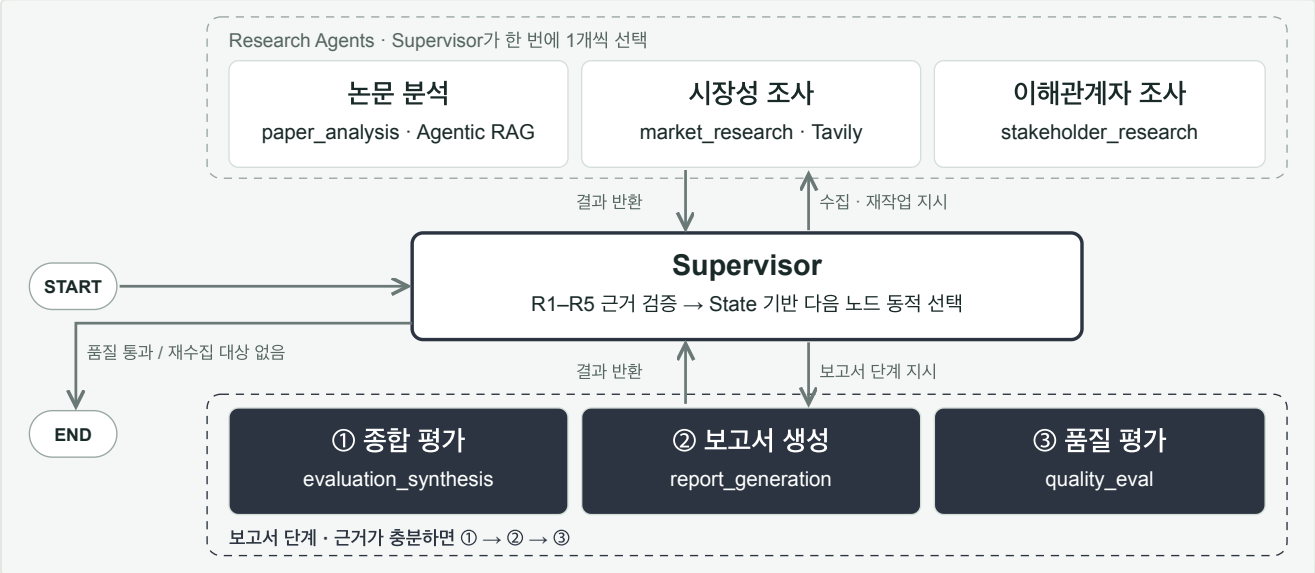
검증된 Claim만으로 보고서 섹션을 구성하고, Claim-Evidence-Source 인용 번호를 템플릿이 결정해 참고문헌까지 추적

Hallucination 완화

LLM 전체 문서 정제를 Jinja2 결정적 렌더링 + 근거 문장 필드 번역으로 축소, 근거 0건이면 Unknown 반환

보고서 품질 게이트

Groundedness · 중립성 · 관점 커버리지 미달 시 Supervisor가 부족한 관점의 Agent만 재수집하도록 판정 규칙 정비



LANGCHAIN · TOOL CALLING

마케팅 리서치 Agent

LangChain 기반 YouTube Tool 개발 — Mock 테스트로는 드러나지 않던 실제 API 실패를 찾아 안정화

2026.09 · 팀 프로젝트 · 담당: YouTube 검색 · 수집 Tool · LangChain · YouTube Data API · Python

7초 이내

경쟁사 분석 초안 생성 (수작업 약 30분)

Tool Calling 인터페이스 설계

채널 검색 · 채널 정보 · 기간별 영상 · 최근 업로드 Tool의 인자 스키마와 호출 조건 정의, 입력 사전 검증

실제 API에서만 나던 실패 해결

Mock 테스트 통과 후 실제 YouTube API end-to-end 검증에서 ID 추출 실패 발견 → 실제 응답 구조와 모의 데이터 차이 추적

재현 테스트 → 수정 → 회귀 테스트

같은 오류를 재현하는 테스트를 먼저 추가하고 파싱 로직 수정, 기존 기능 회귀 테스트까지 연결

API 장애 Fallback

API 장애가 Agent 전체 실패로 이어지지 않도록 fallback 응답 구조 적용



SPRING AI · RAG · TOOL CALLING

티켓 환불 상담 Agent

Spring AI 기반 RAG + Tool Calling 상담 Agent 개발 — 정책 검색 · 예매 시스템 연계 · 승인 워크플로우

2026.08 · 개인 프로젝트 · Spring Boot · Spring AI · pgvector · PostgreSQL

6 / 6

Golden Set 평가 시나리오 통과

RAG + Tool Calling 하이브리드 응답

pgvector 기반 정책 문서 RAG와 예매 조회 · 환불액 계산 Tool을 결합한 응답 파이프라인 구현

Human-in-the-loop 승인 워크플로우

상태 변경 요청은 LLM이 직접 실행하지 않고 승인 대기 티켓으로 분리

Tool 레벨 권한 검증

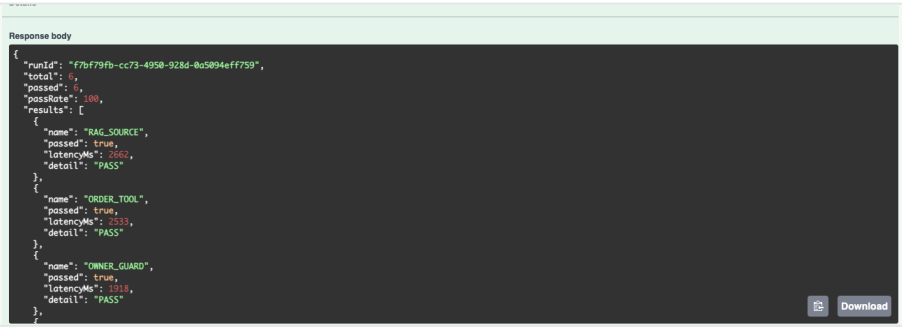
ToolContext의 userId를 조회 조건에 강제해 타인 데이터 접근 차단, 데이터 존재 여부 노출 방지

Memory · Fallback · 계측

세션 단위 메모리, 일시 장애 시 보조 모델 Fallback(변경 요청 제외), Micrometer로 토큰 · 지연 · Fallback 계측



조회와 결정적 계산은 Tool에, 규정은 RAG에, 최종 환불 승인은 사람에게 분리



FINE-TUNING · LORA SFT

sLLM 도메인 파인튜닝 (LoRA SFT)

Qwen2.5-1.5B LoRA SFT — 사내 업무 QA를 반영하지 못하던 범용 모델을 도메인 특화 모델로 개선

SKALA 팀 실습 · 사내 업무 QA 데이터셋 · 담당: 학습 조건 설계 · 실행 · 비교 · Qwen2.5-1.5B · LoRA · PyTorch

20 / 20
Base 모델 대비 1:1 비교 전승

1위
팀 18개 실험 조건 중

Before: 범용 모델의 도메인 한계

Base Qwen2.5-1.5B는 사내 업무 규정과 절차를 답변에 반영하지 못함

사내 업무 QA 데이터셋으로 LoRA SFT

LoRA로 학습 파라미터를 줄여 실습용 사내 질의응답 데이터셋에 SFT, max_length · learning rate 조건을 설계해 비교

After: Base 대비 20문항 전승

동일 질문 20개에 대한 Base vs Fine-tuned 응답을 LLM Judge로 1:1 비교해 20승 0패 0무, Hallucination 검사 5건 모두 통과

최종 모델 선정

팀 18개 조건 중 Total(.3913) · Token F1(.3569) 1위 조건으로 채택

실험	Max Length	Epochs	LoRA Rank	LoRA Alpha	Dropout	Learning Rate	Grad. Accum.	Fine-tuned 승/패/무	Keyword	Token F1	Total	Hallucination	비고
서영3	512	4	16	32	0.05	1e-4	8	20 / 0 / 0	0.3050	0.2980	0.3690	0/5	전승
재경2	512	3	11	22	0	1e-4	8	19 / 0 / 1	0.2100	0.2051	0.2613	0/5	1무
재경(기본)	512	3	16	32	0.05	1e-4	8	19 / 1 / 0	0.2500	0.2081	0.2914	0/5	Base 1승
원준	512	3	8	16	0.05	2e-4	8	19 / 0 / 1	0.2850	0.3306	0.3631	0/5	1무
동건	512	2	16	32	0.05	1e-4	8	17 / 2 / 1	0.1900	0.2351	0.2837	0/5	Base 2승, 1무
서영5	384	4	16	32	0.05	1e-4	8	19 / 0 / 1	0.2750	0.3195	0.3521	0/5	1무
은희 (Trial 1)	384	3	16	32	0.05	1e-4	8	20 / 0 / 0	**0.3250**	0.3100	0.3852	0/5	Keyword 공동 최고, 전승
은희2 (Trial 2·최종)	**384**	**3**	**16**	**32**	**0.05**	**2e-4**	**8**	**20 / 0 / 0**	0.3150	**0.3569**	**0.3913**	**0/5**	**Token F1·Total 최고**
은희3 (Trial 3)	640	3	16	32	0.05	2e-4	8	19 / 0 / 1	0.3200	0.3137	0.3735	0/5	1무
동건2	384	3	8	16	0.05	2e-4	8	19 / 0 / 1	0.2950	0.3002	0.3623	0/5	1무
서영4	384	3	32	32	0.05	1e-4	8	19 / 1 / 0	0.2850	0.3124	0.3585	0/5	Base 1승
동건3	384	3	16	32	0.25	1e-4	8	19 / 1 / 0	**0.3250**	0.3227	0.3891	0/5	Keyword 공동 최고, Total 2위
건호(권장)	384	2	16	32	0.05	1e-4	8	18 / 1 / 1	0.2000	0.2198	0.2850	0/5	Base 1승, 1무
원준2	512	3	16	32	0.10	2e-4	8	19 / 1 / 0	0.2550	0.2953	0.3318	0/5	Base 1승
건호2	512	3	16	32	0.05	5e-5	8	18 / 0 / 2	0.1800	0.2073	0.2682	0/5	2무
건호3	512	4	16	32	0.05	2e-4	8	18 / 1 / 1	0.2950	0.3399	0.3721	0/5	Base 1승, 1무
서영2	384	1	16	32	0.05	1e-4	8	16 / 3 / 1	0.1600	0.1886	0.2268	0/5	3패, 1무
서영1	256	1	4	8	0.05	1e-4	1	14 / 4 / 2	0.1950	0.1517	0.2242	0/5	Base 4승, 2무

FULLSTACK · BACKEND · CLOUD

폴짝 | 폴라로이드 교환 플랫폼

Spring Boot · Vue 기반 C2C 교환 플랫폼 1인 풀스택 개발 및 운영 배포

2026.08 ~ 진행 중 · 개인 프로젝트 · Spring Boot · Vue · PostgreSQL · Cloud Run

End-to-End 서비스 구현

등록 → 탐색 → 제안 → 사진 공개 → 합의 → 채팅 전 과정의 REST API와 Vue 화면 개발

임베딩 기반 시맨틱 검색

pgvector 벡터 검색 + Re-ranking으로 표현이 다른 설명도 매칭

AI 장애 Fallback

임베딩 실패 시 키워드 검색, OCR 실패 시 수동 입력으로 자동 전환해 핵심 기능 가용성 유지

CI/CD · 클라우드 배포

GitHub Actions로 Cloudflare Pages(Vue) · Cloud Run(Spring Boot) · Neon PostgreSQL · R2 배포 자동화



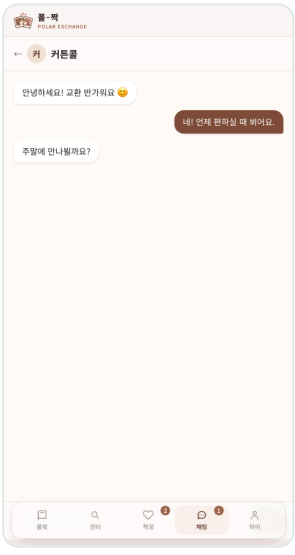
콜북 · 보유 등록



장터 · 조건 탐색



짝꿍 · 제안 · 합의



채팅

MLOPS · MLFLOW · DOCKER

BDI AIOps

MLflow 기반 MLOps 파이프라인 구축 — 비동기 재학습 · 검증 게이트 · 모델 버전 관리

2026.10 · 팀 프로젝트 · 담당: 재학습 · 검증 · 모델 버전 관리 · Docker · MLflow · Python

비동기 재학습

재학습을 백그라운드 작업으로 분리해 API 응답과 학습 시간을 분리

중복 실행 방지

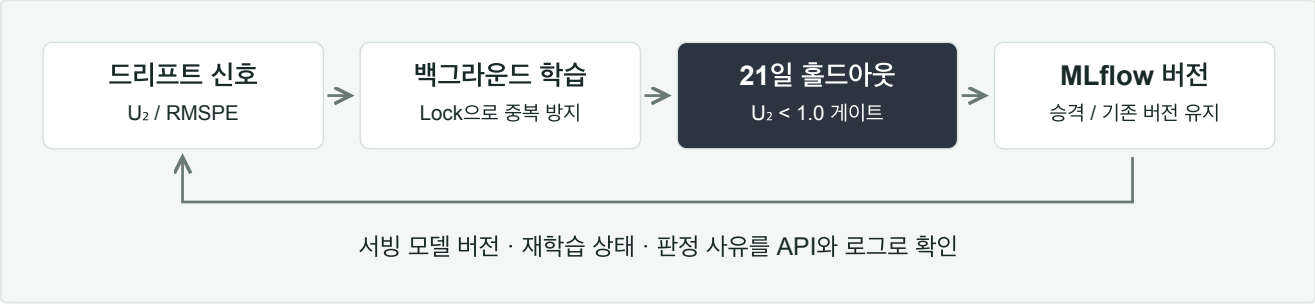
Lock 기반으로 동시 재학습 요청 차단

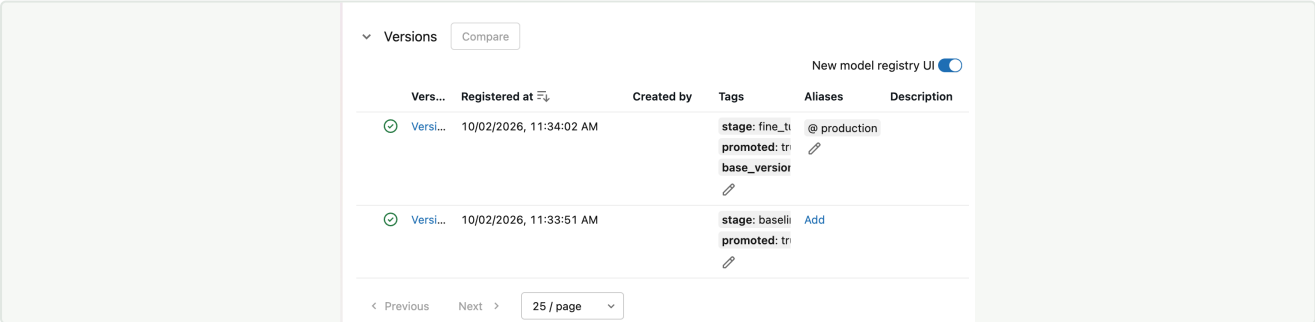
검증 게이트 기반 모델 승격

최근 21거래일 Holdout에서 $U_2 < 1.0$을 충족할 때만 production alias 전환, 미달 시 기존 버전 유지

모델 이력 추적 · 운영 구성

MLflow Model Registry에 버전 · 상태 · 판정 사유 기록, Docker healthcheck · 볼륨 구성





RESEARCH · LLM · XR

XR 상호작용 저작 자동화

LLM + 3D Affordance 기반 XR 상호작용 저작 자동화 연구

연구 · 제1저자 · Python · C# · Unity · LLM · 3D Affordance

제1저자

IEEE ISMAR-Adjunct 2024

LLM 기반 정보 추출

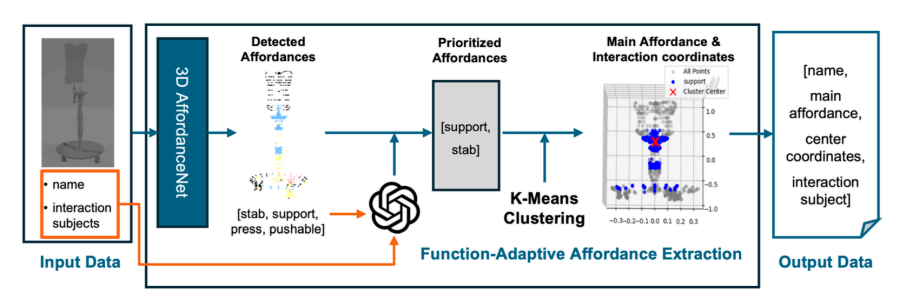
객체명 · 사용 맥락에서 상호작용 유형 · 위치 · 주체를 추출하고 3D Affordance 모델과 결합

모델-엔진 연동 스키마 설계

추론 결과를 JSON 스키마로 구조화하고 Unity 객체 식별자와의 매핑 규칙 정의

AR 프로토타입 구현

추출 결과를 Unity 객체에 자동 적용하는 반자동 저작 파이프라인 구현





ADDITIONAL EXPERIENCE

기타 경험

교육 · 협업 · 연구 · 실험

SK AI 전문가 양성과정 SKALA

2026.07 ~ 2026.12 · 참여 중

- Java · Spring Boot · Vue, Docker · MSA, RAG · SFT · Agent 개발 교육 이수 중
- 팀 프로젝트에서 Tool · 보고서 생성 · MLOps 모듈 담당

SafePass | Scrum Master

팀 B2B 서비스 · Spring Boot · Vue · MSA

- 칸반 · 데일리 스탠드업 운영, 서비스 간 API 의존성 · 블로커 관리
- 작업 등록 → 적합성 확인 → 교육 배정 MVP 기간 내 완성

VR Interaction Affinity · VL-JEPA

모델 연동 · 논문 구현

- V-JEPA 출력을 JSON으로 변환해 Unity Box/Mesh Collider 동적 전환에 연동
- VL-JEPA의 Encoder · Predictor · InfoNCE Loss를 논문 기반으로 구현, 소규모 학습으로 동작 검증

웨이퍼맵 분류 · Spring AI RAG

팀 실험 · 개인 RAG 평가

- 웨이퍼맵: 팀 22개 조건 실험 중 CNN 구조 변경 담당, Test Accuracy 82.96% · Macro-F1 76.70%
- RAG: similarity threshold가 정답 근거까지 제거하는 문제 발견, Golden 10문항 1/10 → 10/10 조건 채택

GitHub · Eunhee-JJ ↗ · YouTube Agent ↗ · 기술 평가 Agent ↗